

Evaluasi Kinerja Algoritma LightGBM dengan Random Oversampling dalam Klasifikasi Tingkat Obesitas

Chesa Saskia Rafika

UPN "Veteran" Jawa Timur, Surabaya

Email : 22081010211@student.upnjatim.ac.id

Abstrak

Obesitas merupakan permasalahan kesehatan global yang terus meningkat dan berisiko menimbulkan berbagai penyakit tidak menular. Klasifikasi tingkat obesitas secara multi-kelas penting untuk mendukung pemetaan risiko dan perencanaan intervensi kesehatan yang lebih tepat sasaran. Namun, ketidakseimbangan kelas pada dataset kesehatan sering menyebabkan model machine learning bias terhadap kelas mayoritas. Penelitian ini bertujuan mengevaluasi kinerja algoritma Light Gradient Boosting Machine (LightGBM) dengan penerapan Random Oversampling (ROS) dalam klasifikasi tingkat obesitas. Dataset Dhaka_Obesity yang digunakan terdiri dari 2.182 data dengan 17 fitur, yang setelah pra-pemrosesan menghasilkan 2.157 data dan enam kelas obesitas. Penelitian dilakukan melalui dua skenario, yaitu LightGBM baseline dan LightGBM dengan Random Oversampling. Hasil evaluasi menunjukkan bahwa model LightGBM + ROS mencapai akurasi **97%**, F1-score macro **0,9679**, dan balanced accuracy **0,9687**, lebih tinggi dibandingkan model baseline dengan akurasi **95%**. Hasil ini menunjukkan bahwa kombinasi LightGBM dan Random Oversampling efektif meningkatkan keadilan dan akurasi klasifikasi tingkat obesitas.

Kata Kunci: Obesitas, LightGBM, Random Oversampling, Class Imbalance, Machine Learning

Abstract

Obesity is a global health problem with increasing prevalence and a strong association with non-communicable diseases. Multi-class classification of obesity levels is essential for detailed risk assessment and targeted health interventions. However, class imbalance in health datasets often causes machine learning models to be biased toward majority classes. This study evaluates the performance of the Light Gradient Boosting Machine (LightGBM) combined with Random Oversampling (ROS) for obesity level classification. The Dhaka_Obesity dataset, consisting of 2,182 records and 17 features, was used, resulting in 2,157 records and six obesity classes after preprocessing. Two experimental scenarios were conducted: a baseline LightGBM model and a LightGBM model with Random Oversampling. The results show that the LightGBM + ROS model achieved an accuracy of **96.99%**, a macro F1-score of **0.9679**, and a balanced accuracy of **0.9687**, outperforming the baseline model with an accuracy of **95.83%**. These findings indicate that combining LightGBM with Random Oversampling effectively improves classification fairness and accuracy, particularly for minority obesity classes.

Keywords: Obesity, LightGBM, Random Oversampling, Class Imbalance, Machine Learning

PENDAHULUAN

Obesitas merupakan salah satu permasalahan kesehatan global yang prevalensinya terus meningkat dan menjadi faktor risiko utama berbagai penyakit tidak menular. Organisasi Kesehatan Dunia (World Health Organization/WHO) melaporkan bahwa prevalensi obesitas global hampir meningkat tiga kali lipat sejak tahun 1975, dengan dampak signifikan terhadap morbiditas dan mortalitas populasi dunia (WHO, 2023). Kondisi obesitas ditandai dengan akumulasi lemak tubuh berlebih yang berkontribusi terhadap munculnya berbagai gangguan kesehatan, seperti diabetes melitus tipe 2, hipertensi, penyakit kardiovaskular, serta gangguan metabolismik lainnya (Hruby & Hu, 2015; Blüher, 2019). Selain berdampak pada aspek klinis, obesitas juga mempengaruhi kualitas hidup, kesehatan mental, serta meningkatkan beban ekonomi akibat tingginya biaya perawatan kesehatan dan menurunnya produktivitas individu usia kerja (Tremmel et al., 2017). Obesitas bersifat multifaktorial karena dipengaruhi oleh interaksi kompleks antara faktor genetik, kebiasaan konsumsi makanan, aktivitas fisik, gaya hidup sedentari, serta karakteristik demografis individu. Hubungan antar faktor tersebut cenderung bersifat non-linear dan saling berinteraksi, sehingga sulit dianalisis secara komprehensif menggunakan pendekatan statistik konvensional yang mengandalkan asumsi linearitas (Jalilzadeh & Goharinezhad, 2025). Oleh karena itu, pendekatan berbasis machine learning menjadi semakin relevan karena mampu mengolah data berdimensi tinggi, mengintegrasikan banyak variabel sekaligus, serta memodelkan hubungan kompleks antar fitur dengan lebih baik (Sharma et al., 2022).

Pemanfaatan machine learning dalam klasifikasi tingkat obesitas telah banyak dilakukan dengan menggunakan data kebiasaan makan, aktivitas fisik, dan kondisi fisik individu. Studi Palechor dan de la Hoz Manotas (2019) menunjukkan bahwa pendekatan computational intelligence mampu menghasilkan estimasi tingkat obesitas yang lebih informatif dibandingkan penggunaan indeks massa tubuh (IMT) semata. Selain itu, penelitian lain melaporkan bahwa algoritma pembelajaran mesin seperti Random Forest, Gradient Boosting, dan Support Vector Machine mampu mencapai performa klasifikasi yang tinggi pada tugas prediksi obesitas berbasis data gaya hidup (Iqbal et al., 2024; Helforoush & Sayyad, 2024). Klasifikasi tingkat obesitas dalam bentuk multi-kelas memiliki peran penting dalam konteks kesehatan masyarakat karena memungkinkan pemetaan risiko yang lebih rinci dibandingkan klasifikasi biner obesitas dan non-obesitas. Pengelompokan individu ke dalam kategori underweight, normal weight, overweight, serta beberapa tingkat obesitas dapat mendukung deteksi dini dan perencanaan intervensi kesehatan yang lebih tepat sasaran (Blüher, 2019). Pendekatan berbasis machine learning terbukti efektif dalam menghasilkan model klasifikasi multi-kelas yang akurat dan aplikatif untuk mendukung pengambilan keputusan di bidang kesehatan (Sharma et al., 2022; Iqbal et al., 2024).

Namun demikian, salah satu tantangan utama dalam klasifikasi tingkat obesitas adalah ketidakseimbangan distribusi kelas (class imbalance). Pada banyak dataset kesehatan, jumlah sampel antar kategori obesitas tidak terdistribusi secara merata, di mana kelas tertentu seperti underweight atau obesitas tingkat lanjut memiliki proporsi yang jauh lebih kecil dibandingkan kelas mayoritas. Kondisi ini berpotensi menyebabkan model machine learning bias terhadap kelas mayoritas dan menghasilkan performa prediksi yang rendah pada kelas minoritas, meskipun nilai akurasi keseluruhan terlihat tinggi (He & Garcia, 2009; Johnson & Khoshgoftaar, 2019). Fenomena tersebut juga ditemukan pada studi klasifikasi obesitas berbasis machine learning, sehingga penanganan ketidakseimbangan data menjadi aspek yang krusial (Iqbal et al., 2024). Dalam pengolahan data tabular di bidang kesehatan, algoritma berbasis ensemble khususnya tree boosting banyak digunakan karena kemampuannya dalam menangkap hubungan non-linear serta interaksi antar fitur. Light Gradient Boosting Machine (LightGBM) merupakan salah satu algoritma boosting yang dikenal memiliki efisiensi komputasi tinggi dan performa kompetitif pada berbagai tugas klasifikasi dan regresi (Ke et

al., 2017). LightGBM telah banyak diaplikasikan pada data kesehatan dan menunjukkan kinerja yang baik pada data tabular dengan kombinasi fitur numerik dan kategorikal, termasuk pada tugas prediksi obesitas (Airlangga, 2025).

Meskipun memiliki performa yang baik, LightGBM tetap sensitif terhadap distribusi kelas pada data latih. Oleh karena itu, penerapan teknik penyeimbangan data menjadi penting untuk meningkatkan keadilan performa antar kelas. Salah satu pendekatan yang umum digunakan adalah oversampling, yaitu dengan meningkatkan jumlah sampel pada kelas minoritas. Random Oversampling (ROS) merupakan teknik oversampling sederhana yang bekerja dengan menduplikasi sampel kelas minoritas tanpa menghasilkan data sintetis baru (He & Garcia, 2009). Teknik ini relatif mudah diimplementasikan dan tetap mempertahankan karakteristik asli data, sehingga banyak digunakan pada studi klasifikasi data kesehatan (Putra & Salam, 2025). Beberapa penelitian melaporkan bahwa kombinasi algoritma boosting dengan teknik Random Oversampling mampu meningkatkan performa klasifikasi, khususnya pada metrik yang sensitif terhadap ketidakseimbangan data seperti balanced accuracy dan F1-score macro (Amatullah et al., 2025). Pendekatan ini dinilai efektif dalam meningkatkan pemerataan performa antar kelas tanpa menimbulkan kompleksitas tambahan pada proses pelatihan model. Berdasarkan uraian tersebut, masih diperlukan kajian empiris yang secara khusus menganalisis pengaruh penerapan Random Oversampling terhadap kinerja LightGBM pada klasifikasi tingkat obesitas, terutama pada dataset dengan ketidakseimbangan kelas yang tergolong moderat. Oleh karena itu, penelitian ini bertujuan untuk mengevaluasi kinerja algoritma LightGBM melalui dua skenario pelatihan, yaitu tanpa penyeimbangan data dan dengan penerapan Random Oversampling pada data latih. Evaluasi dilakukan menggunakan metrik klasifikasi multi-kelas yang mempertimbangkan performa keseluruhan dan keadilan antar kelas, sehingga diharapkan penelitian ini dapat memberikan kontribusi dalam pengembangan sistem prediksi obesitas berbasis machine learning yang lebih akurat dan adil.

METODOLOGI

Bagian ini menjelaskan tahapan sistematis penelitian Evaluasi Kinerja Algoritma LightGBM dengan Random Oversampling dalam Klasifikasi Tingkat Obesitas. Metodologi penelitian dirancang untuk membandingkan performa model Light Gradient Boosting Machine (LightGBM) pada dua skenario, yaitu baseline tanpa penyeimbangan data dan model dengan penerapan Random Oversampling (ROS). Secara umum, alur penelitian meliputi akuisisi data, pra-pemrosesan data, encoding fitur dan target, pembagian data latih dan data uji, perancangan model LightGBM, optimasi hyperparameter, serta evaluasi kinerja model.

1. Akuisisi Data

Dataset yang digunakan pada penelitian ini adalah Dhaka_Obesity.csv, yang berisi data individu terkait kebiasaan makan, aktivitas fisik, gaya hidup, serta kondisi fisik yang berhubungan dengan tingkat obesitas. Dataset ini mencakup fitur numerik dan kategorikal, serta satu variabel target berupa tingkat obesitas (Obesity_level) dalam format multi-kelas. Dataset dimuat dari Google Drive dan diperiksa kelengkapan struktur data, tipe data tiap kolom, serta distribusi awal kelas target untuk mengidentifikasi potensi ketidakseimbangan data sejak tahap awal.

2. Pra-Pemrosesan Data

Tahap pra-pemrosesan bertujuan untuk memastikan data bersih, konsisten, dan siap digunakan pada proses pelatihan model machine learning. Tahapan pra-pemrosesan yang dilakukan meliputi:

1. Pembersihan Nama Kolom

Nama kolom dinormalisasi dengan menghilangkan spasi, simbol khusus, dan

perbedaan format penulisan agar konsisten serta mudah diproses secara programatik. Selanjutnya dilakukan penyeragaman nama kolom ke format yang lebih deskriptif dan terstruktur.

2. Normalisasi Nilai Kategorikal

Nilai pada fitur kategorikal dinormalisasi untuk menghindari variasi penulisan (misalnya perbedaan huruf besar-kecil dan simbol). Selain itu, dilakukan standarisasi kategori pada beberapa fitur seperti frekuensi makan, aktivitas fisik, konsumsi air, dan durasi penggunaan perangkat digital agar setiap kategori memiliki representasi yang konsisten.

3. Penanganan Duplikasi dan Missing Value

Data diperiksa terhadap keberadaan baris duplikat. Seluruh data duplikat dihapus untuk menghindari bias dalam proses pelatihan. Selain itu, dilakukan pengecekan nilai hilang (missing values), dan dataset dipastikan tidak mengandung nilai kosong sebelum tahap encoding dilakukan.

3. Encoding Target dan Fitur

Encoding Variable Target Variable target Obesity_level dinormalisasi dan dipetakan ke dalam bentuk numerik multi-kelas dengan enam kategori Mapping ini memungkinkan penggunaan algoritma klasifikasi multi-kelas berbasis machine learning dan Encoding fitur dilakukan berdasarkan jenis data yaitu:

Tabel 1. Ringkasan Metode Encoding

Metode Encoding	Daftar Variabel
Label Encoding (0/1)	Gender, Family_history_of_overweight, High_caloric_food_consumption, Smoking, Monitor_calories
Ordinal Encoding	Vegetable_consumption_frequency, Daily_main_meals_frequency, Between_meal_food_consumption_frequency, Daily_water_intake, Physical_exercise, Daily_device_usage_duration, Alcohol_intake
One-Hot Encoding	Mode_of_transportation
Mapping label 0–5	Obesity_level (variabel target)

4. Pembagian Data (Train–Test Split)

Dataset yang telah melalui tahap pra-pemrosesan dan encoding selanjutnya dibagi menjadi data latih (80%) dan data uji (20%). Pembagian dilakukan menggunakan metode stratified split untuk mempertahankan proporsi masing-masing kelas obesitas pada data latih dan data uji. Data latih digunakan untuk proses pelatihan dan optimasi model, sedangkan data uji digunakan untuk mengevaluasi kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

5. Penanganan Ketidakseimbangan Data

Untuk mengatasi permasalahan ketidakseimbangan kelas, penelitian ini menerapkan teknik Random OverSampler (ROS) pada salah satu skenario eksperimen. ROS bekerja dengan menduplikasi sampel pada kelas minoritas sehingga distribusi kelas pada data latih menjadi lebih seimbang. Penerapan ROS dilakukan hanya pada data latih dan diintegrasikan langsung ke dalam pipeline pembelajaran, sehingga proses penyeimbangan data berlangsung sebelum pelatihan model dan tidak menimbulkan *data leakage*.

6. Perancangan Model LightGBM

Model klasifikasi yang digunakan pada penelitian ini adalah Light Gradient Boosting Machine (LightGBM) dengan konfigurasi klasifikasi multi-kelas. LightGBM dipilih karena kemampuannya dalam menangani data tabular, memodelkan hubungan non-linear antar fitur, serta efisiensi komputasi yang tinggi. Model dikonfigurasikan dengan jumlah kelas sebanyak enam, pengaturan *random state* untuk menjaga reproducibilitas hasil eksperimen, serta pemanfaatan *multi-threading* guna mempercepat proses pelatihan. Optimasi hiperparameter dilakukan menggunakan metode GridSearchCV dengan skema validasi silang 5-fold. Parameter yang dioptimasi meliputi jumlah daun (*num_leaves*), kedalaman pohon (*max_depth*), laju pembelajaran (*learning_rate*), jumlah *estimator*, serta jumlah minimum data pada daun (*min_data_in_leaf*). Proses optimasi bertujuan untuk memperoleh kombinasi parameter terbaik yang mampu meningkatkan kinerja model secara keseluruhan. Sebagai metrik evaluasi pada proses validasi silang digunakan balanced accuracy, karena metrik ini lebih representatif dalam menilai performa model pada permasalahan klasifikasi multi-kelas dengan distribusi data yang tidak seimbang. Penggunaan balanced accuracy memungkinkan evaluasi yang lebih adil terhadap seluruh kelas obesitas, khususnya kelas minoritas yang sering terabaikan oleh metrik akurasi konvensional.

7. Skenario Eksperimen

Penelitian ini membandingkan dua skenario eksperimen utama untuk mengevaluasi pengaruh penerapan teknik penyeimbangan data terhadap kinerja model klasifikasi tingkat obesitas. Kedua skenario dilatih dan diuji menggunakan dataset yang sama, sehingga perbandingan performa antar skenario dapat dilakukan secara adil dan objektif. Adapun skenario eksperimen yang digunakan adalah sebagai berikut:

- Baseline, yaitu model Light Gradient Boosting Machine (LightGBM) yang dilatih menggunakan data latih asli tanpa penerapan teknik penyeimbangan kelas. Skenario ini digunakan sebagai acuan untuk mengetahui kinerja dasar model ketika dihadapkan pada distribusi kelas yang tidak seimbang.
- LightGBM dengan Random OverSampler, yaitu model LightGBM yang dilatih menggunakan data latih hasil penerapan Random OverSampler (ROS). Pada skenario ini, kelas minoritas pada data latih diperbanyak melalui proses oversampling untuk menghasilkan distribusi kelas yang lebih seimbang, dengan tujuan meningkatkan performa prediksi pada seluruh kelas obesitas.

Dengan membandingkan hasil evaluasi dari kedua skenario tersebut, penelitian ini bertujuan untuk menganalisis sejauh mana penerapan Random OverSampler mampu meningkatkan kinerja dan keadilan klasifikasi model LightGBM, khususnya pada kelas-kelas dengan jumlah data yang lebih sedikit.

8. Evaluasi Kinerja Model

Setelah model Light Gradient Boosting Machine (LightGBM) selesai dilatih menggunakan data latih, tahap selanjutnya adalah melakukan evaluasi kinerja model terhadap data uji, yaitu data yang tidak pernah digunakan dalam proses pelatihan maupun penyeimbangan data. Evaluasi ini bertujuan untuk menilai kemampuan model dalam mengklasifikasikan tingkat obesitas individu ke dalam enam kelas, yaitu Insufficient Weight, Normal Weight, Overweight, Obesity Type I, Obesity Type II, dan Obesity Type III, pada data yang benar-benar baru bagi model. Metode evaluasi yang digunakan mengacu pada beberapa metrik utama yang umum diterapkan pada permasalahan klasifikasi multi-kelas, khususnya pada kondisi distribusi kelas yang tidak seimbang, yaitu akurasi, precision, recall, F1-score, dan balanced accuracy:

1. Akurasi: Mengukur proporsi prediksi yang benar terhadap total keseluruhan data uji.

$$Akurasi = \frac{TP+TN}{TP+TN+FP+FN} \quad (1)$$

2. Precision: Menilai ketepatan model dalam memprediksi suatu kelas positif, yaitu seberapa banyak dari prediksi suatu kelas yang benar-benar berasal dari kelas tersebut.

$$Presisi = \frac{TP}{TP+FP} \quad (2)$$

3. Recall: Menggambarkan kemampuan model dalam menemukan seluruh data yang benar-benar termasuk ke dalam suatu kelas (sensitivitas).

$$Recall = \frac{TP}{TP+FN} \quad (3)$$

4. F1-Score: Merupakan rata-rata harmonik antara precision dan recall. Metrik ini penting terutama ketika distribusi data antar kelas tidak seimbang sempurna, karena F1-Score memberikan gambaran yang lebih seimbang antara kedua aspek tersebut.

$$F1 - Score = \frac{2.Presisi.Recall}{Presisi+Recall} \quad (4)$$

Penjelasan:

True Positive(TP)=Jumlah kasus positif yang diprediksi benar

False Positive(FP)=Jumlah kasus negatif yang diprediksi positif secara salah

False Negative (FN)=Jumlah kasus positif yang diprediksi negatif secara salah

True Negative (TN)=Jumlah kasus negatif yang diprediksi benar

Selain itu, confusion matrix juga digunakan untuk menganalisis pola kesalahan klasifikasi antar tingkat obesitas secara lebih rinci. Melalui confusion matrix, dapat diketahui kelas obesitas yang telah dikenali dengan baik oleh model serta kelas yang masih sering tertukar dengan kelas lainnya. Tahap evaluasi ini diterapkan pada dua skenario eksperimen, yaitu LightGBM tanpa penyeimbangan data (baseline) dan LightGBM dengan Random OverSampler. Perbandingan hasil evaluasi dari kedua skenario tersebut menjadi dasar untuk menilai pengaruh penerapan Random Oversampling terhadap peningkatan performa dan keadilan klasifikasi tingkat obesitas, khususnya pada kelas-kelas minoritas.

HASIL DAN PEMBAHASAN

Hasil

1. Hasil Pra-Pemrosesan Data

Dataset Dhaka_Obesity yang digunakan dalam penelitian ini terdiri atas 2.182 data dengan 17 atribut, yang mencakup karakteristik demografis, kondisi fisik, kebiasaan makan, aktivitas fisik, dan gaya hidup individu. Variabel target berupa tingkat obesitas memiliki enam kelas, yaitu *Insufficient Weight*, *Normal Weight*, *Overweight*, *Obesity Type I*, *Obesity Type II*, dan *Obesity Type III*. Tahap pra-pemrosesan dilakukan untuk memastikan konsistensi dan kualitas data sebelum digunakan dalam pelatihan model. Proses ini meliputi pembersihan nama kolom, normalisasi nilai kategorikal, serta penghapusan data duplikat. Hasil pra-pemrosesan menunjukkan bahwa terdapat 25 data duplikat yang kemudian dihapus, sehingga jumlah data akhir yang digunakan menjadi 2.157 data. Seluruh atribut dipastikan tidak memiliki nilai hilang (*missing value*) setelah proses pembersihan. Distribusi kelas target sebelum dan sesudah pra-pemrosesan relatif tidak seimbang, di mana kelas *Normal Weight* dan *Overweight* memiliki jumlah data lebih besar dibandingkan kelas obesitas tingkat lanjut. Kondisi ini mengindikasikan adanya permasalahan class imbalance, sehingga diperlukan strategi penanganan khusus pada tahap pemodelan.

Tabel 2. Distribusi Kelas Tingkat Obesitas (Sebelum Pra-Pemrosesan)

No	Kelas Tingkat Obesitas	Jumlah Data
1	Normal Weight	530
2	Overweight	423
3	Insufficient Weight	378
4	Obesity Type I	317
5	Obesity Type II	283
6	Obesity Type III	251
	Total	2.182

Tabel 3. Ringkasan Dataset Setelah Pra-Pemrosesan

Keterangan	Nilai
Jumlah data awal	2.182
Data duplikat	25
Data akhir	2.157
Jumlah fitur	17
Missing value	0
Jumlah kelas	6

2. Hasil Encoding dan Pembagian Data

Variabel target tingkat obesitas dikonversi ke dalam bentuk numerik dengan rentang label 0 hingga 5 untuk mendukung proses klasifikasi multi-kelas. Fitur kategorikal pada dataset di encoding menggunakan pendekatan yang sesuai dengan karakteristik data, yaitu *label encoding* untuk fitur biner, *ordinal encoding* untuk fitur berurutan, serta *one-hot encoding* untuk fitur nominal. Setelah proses encoding, dataset dibagi menjadi data latih sebesar 80% (1.725 data) dan data uji sebesar 20% (432 data) menggunakan metode stratified split. Pembagian ini memastikan proporsi masing-masing kelas obesitas tetap terjaga pada data latih dan data uji, sehingga proses pelatihan dan evaluasi model dapat dilakukan secara adil dan representatif.

Tabel 4. Jenis Encoding pada Setiap Fitur

	Column	Encoding_Type
0	Gender	Label (Binary)
1	Family_history_of_overweight	Label (Binary)
2	High_caloric_food_consumption	Label (Binary)
3	Smoking	Label (Binary)
4	Monitor_calories	Label (Binary)
5	Vegetable_consumption_frequency	Ordinal
6	Daily_main_meals_frequency	Ordinal
7	Between_meal_food_consumption_frequency	Ordinal
8	Daily_water_intake	Ordinal
9	Physical_exercise	Ordinal
10	Daily_device_usage_duration	Ordinal
11	Alcohol_intake	Ordinal
12	Mode_of_transportation	One-Hot

Tabel 5. Distribusi Kelas pada Data Latih dan Data Uji

Obesity_level	Train_Count	Test_Count
0	287	72
1	423	106
2	335	84
3	254	63
4	226	57
5	200	50

3. Hasil Pelatihan Model LightGBM

Penelitian ini mengevaluasi dua skenario eksperimen, yaitu LightGBM baseline tanpa penyeimbangan data dan LightGBM dengan Random OverSampler (ROS). Pada kedua skenario, proses pelatihan dilakukan menggunakan GridSearchCV dengan validasi silang 5-fold dan metrik evaluasi balanced accuracy. Pada skenario baseline, model LightGBM menghasilkan nilai *balanced accuracy* sebesar 0,9638 pada data uji. Hasil ini menunjukkan bahwa model mampu mengklasifikasikan tingkat obesitas dengan baik, namun masih terdapat potensi bias terhadap kelas mayoritas. Pada skenario LightGBM dengan Random

OverSampler, penerapan teknik oversampling pada data latih menghasilkan peningkatan performa. Nilai *balanced accuracy* meningkat menjadi 0,9687, disertai peningkatan nilai F1-score macro dari 0,9609 pada baseline menjadi 0,9679. Hal ini menunjukkan bahwa ROS mampu membantu model dalam mengenali kelas minoritas dengan lebih baik tanpa menurunkan performa pada kelas mayoritas.

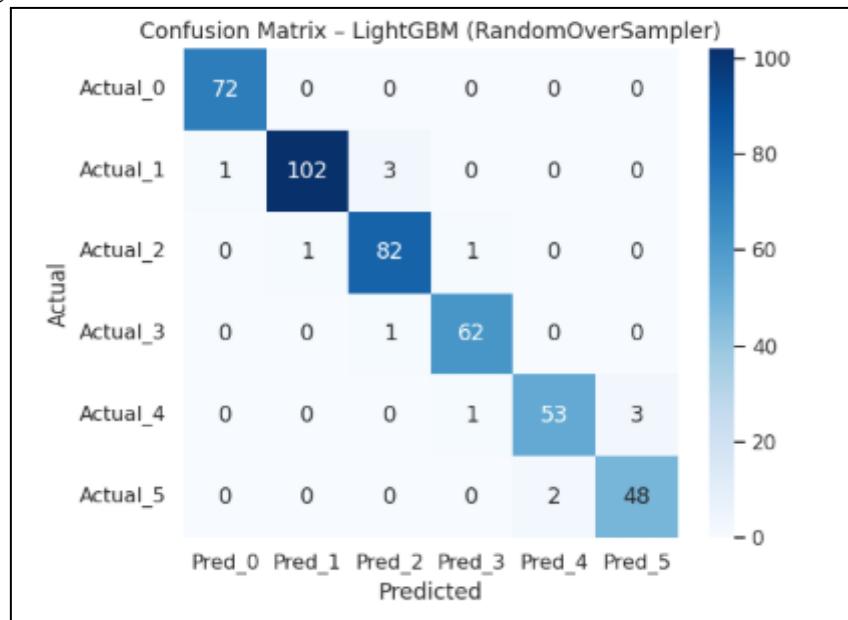
4. Evaluasi dan Analisis Kinerja Model

Evaluasi kinerja model dilakukan menggunakan beberapa metrik, yaitu akurasi, precision, recall, F1-score, dan balanced accuracy, serta dianalisis lebih lanjut melalui confusion matrix. Hasil evaluasi menunjukkan bahwa model LightGBM + Random OverSampler mencapai akurasi sebesar 96,99%, lebih tinggi dibandingkan model baseline yang mencapai 95,83%. Selain itu, peningkatan yang lebih signifikan terlihat pada metrik F1-score macro, yang mencerminkan performa model secara seimbang pada seluruh kelas obesitas.

Tabel 6. Perbandingan Kinerja Model Baseline vs ROS

Skenario Model	Accuracy	F1-score Macro	Balanced Accuracy	Waktu Training (detik)
LightGBM Baseline	0.9583	0.9609	0.9638	67.40
LightGBM+Random OverSampler	0.9699	0.9679	0.9687	245.07

Berdasarkan Tabel 6, penerapan Random Over Sampler memberikan peningkatan kinerja pada seluruh metrik evaluasi utama, khususnya F1-score macro dan balanced accuracy. Meskipun waktu pelatihan meningkat dibandingkan skenario baseline, peningkatan performa yang diperoleh menunjukkan bahwa penggunaan ROS menghasilkan model dengan prediksi yang lebih adil antar kelas obesitas.



Gambar 1. Confusion Matrix Model Terbaik (LightGBM + ROS)

Analisis confusion matrix pada Gambar 1 menunjukkan bahwa model LightGBM + Random OverSampler mampu mengurangi kesalahan klasifikasi pada kelas dengan jumlah

data relatif sedikit, seperti Insufficient Weight dan Obesity Type III. Hal ini mengindikasikan bahwa teknik oversampling berhasil meningkatkan sensitivitas model terhadap kelas minoritas, sehingga menghasilkan prediksi yang lebih seimbang dan adil antar kelas.

Pembahasan

Berdasarkan hasil eksperimen yang telah dilakukan, dapat diketahui bahwa algoritma Light Gradient Boosting Machine (LightGBM) menunjukkan kinerja yang sangat baik dalam mengklasifikasikan tingkat obesitas berbasis data tabular yang terdiri dari kombinasi fitur numerik dan kategorikal. Pada skenario baseline, model telah mampu mencapai nilai *balanced accuracy* yang tinggi, menandakan bahwa LightGBM secara alami cukup efektif dalam menangani hubungan non-linear antar fitur gaya hidup dan kondisi fisik individu. Namun demikian, hasil evaluasi juga menunjukkan adanya potensi bias terhadap kelas mayoritas akibat distribusi data yang tidak seimbang. Penerapan Random OverSampler (ROS) pada data latih terbukti memberikan dampak positif terhadap kinerja model. Peningkatan nilai *F1-score macro* dan *balanced accuracy* pada skenario LightGBM + ROS menunjukkan bahwa model menjadi lebih seimbang dalam mengenali seluruh kelas obesitas, termasuk kelas minoritas seperti *Insufficient Weight* dan *Obesity Type III*. Hal ini mengindikasikan bahwa teknik oversampling sederhana seperti ROS mampu memperbaiki representasi kelas minoritas tanpa mengubah karakteristik asli data.

Analisis lebih lanjut melalui confusion matrix memperkuat temuan tersebut. Model dengan ROS menunjukkan penurunan jumlah kesalahan klasifikasi pada kelas-kelas dengan jumlah data lebih sedikit, yang sebelumnya cenderung salah diprediksi pada skenario baseline. Kondisi ini menegaskan bahwa peningkatan performa tidak hanya tercermin pada nilai akurasi keseluruhan, tetapi juga pada keadilan prediksi antar kelas, yang menjadi aspek penting dalam konteks aplikasi kesehatan. Meskipun penerapan Random OverSampler menyebabkan peningkatan waktu pelatihan model secara signifikan, trade-off tersebut masih dapat diterima mengingat peningkatan performa yang diperoleh. Dalam konteks sistem pendukung keputusan di bidang kesehatan, model dengan akurasi dan keadilan klasifikasi yang lebih tinggi lebih diutamakan dibandingkan efisiensi waktu pelatihan semata, terutama karena proses pelatihan tidak dilakukan secara real-time. Secara keseluruhan, hasil penelitian ini menunjukkan bahwa kombinasi LightGBM dan Random OverSampler merupakan pendekatan yang efektif untuk klasifikasi tingkat obesitas pada dataset dengan distribusi kelas yang tidak seimbang. Temuan ini memperkuat pentingnya penanganan ketidakseimbangan data dalam pengembangan model machine learning, khususnya pada permasalahan klasifikasi multi-kelas di domain kesehatan.

SIMPULAN (PENUTUP)

Berdasarkan tujuan penelitian dan hasil analisis yang telah dilakukan, dapat disimpulkan bahwa algoritma Light Gradient Boosting Machine (LightGBM) memiliki kemampuan yang sangat baik dalam melakukan klasifikasi tingkat obesitas berbasis data tabular yang mencakup faktor demografis, kondisi fisik, kebiasaan makan, aktivitas fisik, dan gaya hidup individu. Model LightGBM mampu memodelkan hubungan non-linear antar fitur secara efektif, sehingga menghasilkan performa klasifikasi yang tinggi pada permasalahan multi-kelas tingkat obesitas. Hasil penelitian menunjukkan bahwa permasalahan ketidakseimbangan kelas (class imbalance) berpengaruh terhadap keadilan performa model, khususnya pada kelas obesitas dengan jumlah data yang lebih sedikit. Penerapan Random OverSampler (ROS) pada data latih terbukti mampu meningkatkan kinerja model secara lebih merata pada seluruh kelas obesitas. Hal ini ditunjukkan oleh peningkatan nilai *F1-score macro* dan *balanced accuracy*, yang merepresentasikan kemampuan model dalam mengenali kelas mayoritas maupun minoritas secara seimbang. Meskipun penggunaan Random

OverSampler menyebabkan peningkatan waktu pelatihan model, trade-off tersebut masih dapat diterima mengingat peningkatan kualitas prediksi yang diperoleh. Dalam konteks aplikasi kesehatan, keadilan dan akurasi klasifikasi antar kelas memiliki peran yang lebih penting dibandingkan efisiensi waktu pelatihan semata, karena kesalahan prediksi pada kelas tertentu dapat berdampak pada pengambilan keputusan klinis dan perencanaan intervensi kesehatan. Secara keseluruhan, penelitian ini membuktikan bahwa kombinasi LightGBM dan Random OverSampler merupakan pendekatan yang efektif dan layak digunakan untuk klasifikasi tingkat obesitas pada dataset dengan distribusi kelas yang tidak seimbang. Pendekatan ini berpotensi dikembangkan lebih lanjut sebagai dasar sistem pendukung keputusan di bidang kesehatan, khususnya dalam pemetaan risiko obesitas dan perencanaan strategi pencegahan berbasis data.

DAFTAR PUSTAKA

- Airlangga, G. (2025). *A comparative analysis of machine learning models for obesity prediction*. Jurnal Informatika Ekonomi Bisnis, 7(1), 1–5
- Amatullah, S., Lailatul, A., Wijayanto, D., Wibowo, M. H., & Purwanto, A. (2025). Studi komparatif berbagai metode boosting pada data penerima Program Keluarga Harapan menggunakan random oversampling. *TELKA*, 11(3), 708–720.
- Blüher, M. (2019). Obesity: global epidemiology and pathogenesis. *Nature Reviews Endocrinology*, 15(5), 288–298.
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284.
- Helforoush, Z., & Sayyad, H. (2024). Prediction and classification of obesity risk based on a hybrid metaheuristic machine learning approach. *Frontiers in Big Data*, 7, 1469981.
- Hruby, A., & Hu, F. B. (2015). The epidemiology of obesity: a big picture. *Pharmacoconomics*, 33(7), 673–689.
- Iqbal, M., Lisnawaty, L., Dharmawan, W. S., & Septian, R. (2024). Prediction of obesity categories based on physical activity using machine learning algorithms. *Journal of Computer Networks, Architecture and High Performance Computing*, 6(3), 1025–1034.
- Jalilzadeh, M., & Goharinezhad, S. (2025). Exploring the multifaceted factors influencing overweight and obesity: a scoping review. *Frontiers in Public Health*, 13, 1540756.
- Johnson, J. M., & Khoshgoftaar, T. M. (2019). Survey on deep learning with class imbalance. *Journal of Big Data*, 6(27).
- Ke, G., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.
- Palechor, F. M., & de la Hoz Manotas, A. (2019). Estimation of obesity levels based on dietary habits and physical condition using computational intelligence. *Data in Brief*, 25, 104344.
- Putra, A., & Salam, A. (2025). Comparative performance of SMOTE, ADASYN and random oversampling on health datasets. *Journal of Artificial Intelligence and Computing*.
- World Health Organization. (2023). *Obesity and overweight*. WHO.